Assignment 1 Big Data



EMMANUEL CANDRA SULISTIAWAN

2702715744

GRADUATE PROGRAM

MASTER OF COMPUTER SCIENCE

BINA NUSANTARA UNIVERSITY

2026

Link Video : https://youtu.be/YdbD2h7qf-g?si=BW827duDTa3TwC2n

Link PPt : https://canva.link/cb5no9lnlscemh0

DAFTAR ISI

DAFTAR ISI..... 2
DAFTAR GAMBAR.....3
DAFTAR TABEL.....3
1. Pendahuluan.....4
1.1 Latar belakang masalah..... 4
1.2 Market and Business Driver..... 4
1.3 Pemangku kepentingan yang terlibat..... 5
2. Rancangan Solusi Big Data.....5
Gambar 1. Arsitektur big Data..... 5
2.1 Metode Pengumpulan Data.....5
2.2 Teknologi Penyimpanan Data.....6
2.3. Processing Framework.....6
3. Tata Kelola IT..... 7
3.1 Security.....7
3.2 Compliance.....7
3.3 Data Privacy..... 7
3.4 Data Quality.....7
4. Data.....7
4.1 Deskripsi Data..... 7
4.2 Model Data..... 8
Referensi..... 9

DAFTAR GAMBAR

Gambar 1. Arsitektur Big Data..... 5

DAFTAR TABEL

1. Pendahuluan

1.1 Latar belakang masalah

Dewasa ini, energi semakin dibutuhkan oleh masyarakat dunia. Perkembangan teknologi, terutama di bidang *Artificial Intelligence (AI),* memerlukan energi yang sangat besar. Perusahaan teknologi raksasa seperti Google, Microsoft dan Meta menggunakan data center untuk melatih ataupun menjalankan model AI tersebut. Data center memproses data yang sangat besar sehingga dibutuhkan energi yang besar juga. Kebutuhan data center menambah beban permintaan energi global yang sudah tertekan akibat krisis pasokan.

Perang timur tengah telah membuat energi semakin sulit diperoleh. Rantai pasokan minyak dan gas alam terganggu karena hancurnya infrastruktur pendukung transportasi dan blokade selat hormuz. Negara-negara kemudian mencari solusi sumber energi lain yang dapat lebih mudah didapatkan.

Batu bara menjadi solusi yang dipilih untuk memenuhi kekurangan energi tersebut. Batu bara di pilih oleh karena biayanya yang murah dan memiliki infrastruktur yang lebih mudah dibandingkan dengan energi ramah lingkungan seperti nuklir, kincir angin, panel surya. Namun, batu bara memiliki tingkat kecelakaan yang lebih tinggi dibandingkan energi-energi bersih tersebut. Kecelakaan pada pemrosesan batu bara terjadi secara rutin.

Oleh karena itu, diperlukan monitoring untuk mengatasi dan mencegah kecelakan tersebut. Big data diperlukan untuk hal tersebut karena banyaknya tambang yang ada dan kecelakaan yang terjadi cukup sering. Selain itu, laporan tentang kecelakaan cukup beragam ada yang terstruktur maupun tidak terstruktur.

1.2 Market and Business Driver

Market Driver:

- Peningkatan kebutuhan data center di US : Investasi data center di US pada tahun 2024 ada di angkat sekitar 500 Miliar USD naik menjadi hingga 2 kali yakni 1 trilliun USD sebelum tahun 2027

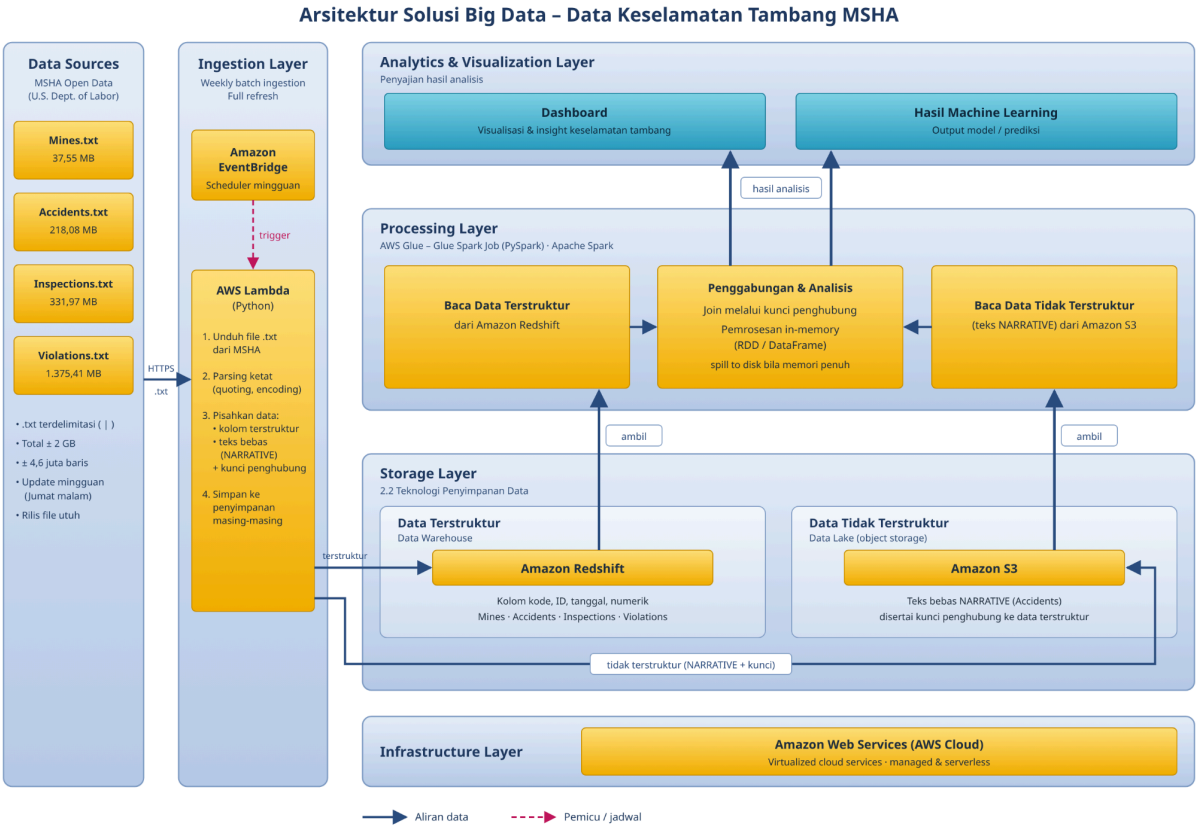
Business Driver:

- Manajemen resiko untuk mengurangi terjadinya kecelakaan.
- Kepatuhan terhadap regulasi untuk menghindari penutupan ataupun denda.

1.3 Pemangku kepentingan yang terlibat

- Perusahaan pengolah listrik dari batu bara
- Perusahaan pemilik data center
- Dinas sosial

2. Rancangan Solusi Big Data



Gambar 1. Arsitektur big Data

2.1 Metode Pengumpulan Data

Data yang digunakan dalam penelitian ini diperoleh dari portal data terbuka milik U.S. Department of Labor, khususnya Mine Safety and Health Administration (MSHA). Dataset diunduh secara berkala melalui tautan resmi MSHA (Mine Data Retrieval System / MDRS). Berdasarkan dokumentasi resmi MSHA, pembaruan dataset dilakukan secara mingguan setiap Jumat malam. Oleh karena itu, strategi pengumpulan data dilakukan secara batching mingguan (weekly batch ingestion).

Skema ingestion menggunakan metode full refresh mengingat MSHA menyediakan file data utuh (berformat .txt terdelimitasi) yang diperbarui secara menyeluruh pada setiap siklus rilis, bukan dalam bentuk aliran data linier (data stream). Alur pengumpulan data dirancang sebagai berikut:

- Unduh Teks & Konversi Format: Script Python yang berjalan secara otomatis (scheduled pipeline via AWS Lambda / EventBridge) mengunduh file .txt mentah langsung dari server MSHA. Script ini memproses ekstraksi dan konversi format ke .csv dengan menerapkan quoting/parsing rules yang ketat, khususnya pada kolom free-text seperti NARRATIVE pada dataset Accidents, guna mencegah pergeseran kolom (column shifting) akibat karakter koma atau newline dalam teks.
- Penyimpanan Mentah (Raw Staging): File .csv hasil konversi langsung diunggah ke bucket Amazon S3 pada area Raw Zone.

2.2 Teknologi Penyimpanan Data

Sistem penyimpanan data dibangun berbasis cloud menggunakan ekosistem Amazon Web Services (AWS) dengan menerapkan pola arsitektur Data Lakehouse (kombinasi Data Lake dan Data Warehouse). Pemilihan infrastruktur cloud AWS didasarkan pada jaminan Service Level Agreement (SLA) ketersediaan tinggi (high availability) dan durabilitas data hingga 99,999999999% (11 sembilan) pada Amazon S3, sehingga eliminasi manajemen replikasi manual dapat tercapai.

Sistem penyimpanan dibagi menjadi dua tingkatan (tiered storage) yang disesuaikan dengan fungsi dan beban kerja (workload):

- Amazon S3 (Data Lake / Raw Zone):

  Amazon S3 difungsikan sebagai data lake untuk menyimpan file mentah .csv hasil ingestion sebelum diproses. S3 digunakan sebagai area penampungan utama (landing zone) karena skalabilitasnya yang tak terbatas serta efisiensi biaya penyimpanan data berukuran besar (~2 GB).

- Amazon Redshift (Data Warehouse / Analytical Zone):
  Amazon Redshift difungsikan sebagai Data Warehouse terstruktur.

2.3. Processing Framework

Kerangka kerja pemrosesan data menggunakan AWS Glue, sebuah layanan Extract, Transform, and Load (ETL) bersifat serverless yang menjalankan mesin Apache Spark di belakangnya. Tipe job yang digunakan adalah Glue Spark Job (berbasis PySpark) untuk memanfaatkan keunggulan komputasi terdistribusi.

Apache Spark dipilih karena melakukan eksekusi pemrosesan data secara in-memory (menggunakan Resilient Distributed Dataset / RDD dan DataFrame), berbeda dengan Hadoop MapReduce yang menuliskan hasil perantara (intermediate results) ke dalam disk (HDFS) pada setiap tahapan Map dan Reduce. Pemrosesan in-memory ini meningkatkan

kecepatan komputasi secara signifikan. Jika memori melampaui batas, Spark secara otomatis melakukan mekanisme spill to disk.

3. Tata Kelola IT

3.1 Security

Jika ada orang yang mengubah data yang kita punya dapat mempengaruhi hasil AI yang digunakan, sehingga tidak boleh ada pihak luar yang dapat mengedit data. Oleh karena itu pada AWS kita dapat mengatur akses berdasarkan IAM sehingga bagian analisis, tidak dapat mengganti data. Selain itu kita dapat memverifikasi hasilnya dengan mengecek ke sumber utama yakni website MSHA.

3.2 Compliance

Data disimpan di AWS dan sesuai dengan region tempat bucketnya berada. Dataset yang ada juga lisensinya bebas digunakan untuk analisa.

3.3 Data Privacy

Dataset merupakan dataset publik, jadi tidak perlu ada penanganan khusus untuk privacy.

3.4 Data Quality

Kualitas data perlu diperhatikan untuk konsistensi. Karena data merupakan laporan kecelakaan, maka tidak semua hari ada data nya. Data juga merupakan gabungan antara data terstruktur dan tidak terstruktur. Untuk data terstruktur bisa terdapat nilai yang hilang (missing values) sehingga perlu kita isi baik menggunakan pendekatan statistik (rata - rata, median, modus) ataupun label khusus. Untuk data tidak terstruktur yang berisi teks, bisa terdapat typo ataupun kalimat yang terpotong. Code https://colab.research.google.com/drive/1IKOqwyx-5LudkYKyRNBlRFOzULQMKCMS?usp=sharing

4. Data

4.1 Deskripsi Data

Data yang digunakan dalam penelitian ini diperoleh dari portal data terbuka milik U.S. Department of Labor. Data terdiri dari 4 file txt yakni file mines (37,55 MB), file accidents (218,08 MB), file inspections (331,97 MB), dan file violations (1375.41 MB). File mines menjelaskan detail tentang tambah seperti lokasi, status, dan jenis tambang. File Accidents

menjelaskan tentang kecelakan yang terjadi dan data detail kecelakaannya mulai dari waktu, perangkat yang digunakan, dan juga deskripsi kejadian yang terjadi. File inspections merupakan laporan inspeksi yang terjadi. Sedangkan violations adalah violasi yang ditemukan pada suatu inspeksi. Data - data tersebut merupakan data terstruktur tabular, namun terdapat data yang tidak terstruktur seperti penjelasan kejadian kecelakaan.

5 V pada data:

- Volume : volume data cukup besar hingga kurang lebih 2 GB dengan 4,6 juta baris.
- Variety: data cukup beragam terdapat tanggal, lokasi, angka nilai, pengukuran, teks narasi
- Velocity : untuk dataset ini tidak real time, namun tetap terdapat data baru yang di update secara berkala tiap minggunya
- Value : Data memiliki nilai yang dapat berguna untuk mengetahui detail kejadian, inspeksi
- Veracity : Mayoritas data sudah tidak ada nilai null.

4.2 Model Data

Data secara umum disimpan secara tabel relasiona. Namun terdapat juga teks narative yang masih dalam bentuk txt untuk menyimpan data narasi dari kejadian kecelakaan.

Untuk data yang tersimpan secara relasional sendiri kita hubungkan dengan ID yang sama. Mines ID terdapat pada ke 4 dataset, Inspection dan violation dihubungkan lewat EVENT_NO. Sedangkan untuk data narasi yang disimpan dalam teks tetap akan memiliki DOCUMENT_NO sebagai key untuk menghubungkannya dengan data yang terstruktur.

Referensi

Goldman Sachs. (2024). AI, data centers and the coming US power surge. Goldman Sachs Research. https://www.goldmansachs.com/insights/pages/gs-research/ai-data-centers-and-the-coming-us-power-surge/full-report.pdf

International Energy Agency. (2023). Coal 2023: Analysis and forecast to 2026. IEA Publications. https://www.iea.org/reports/coal-2023

International Energy Agency. (2024). Electricity 2024: Analysis and forecast to 2026. IEA Publications. https://www.iea.org/reports/electricity-2024

Markandya, A., & Wilkinson, P. (2007). Electricity generation and health. The Lancet, 370(9591), 979–990. https://doi.org/10.1016/S0140-6736(07)61253-7

Song, X., Jiao, L., & Dong, D. (2020). Application of big data technology in coal mine safety management. IEEE Access, 8, 185120–185130. https://doi.org/10.1109/ACCESS.2020.3029123

U.S. Energy Information Administration. (2023). World oil transit chokepoints. U.S. Department of Energy. https://www.eia.gov/international/analysis/specialtopics/World_Oil_Transit_Chokepoints

Zhang, L., Wang, Y., & Liu, Q. (2022). Natural language processing for unstructured accident reports in mining safety: A systematic review and framework. Safety Science, 148, Article 105658. https://doi.org/10.1016/j.ssci.2021.105658